Análisis Exploratorio de Datos - Cardio

Gastón Rodrigues

Table of contents

1 Introducción 2

2 Importación y descripción del dataset 2

3 Identificación y clasificación de las variables 4

4 Medidas de posición de las variables numéricas 5
- 4.1 Función para calcular la moda . . . 5
- 4.2 Variables numéricas . . . 5
- 4.3 Medidas de tendencia central y cuartiles . . . 6
- 4.4 Deciles . . . 7
- 4.5 Percentiles . . . 7

5 Análisis de variables categóricas 8
- 5.1 Moda de las variables categóricas . . . 9
- 5.2 Tablas de frecuencia y gráficos de barras . . . 9
  - 5.2.1 Género . . . 9
  - 5.2.2 Colesterol . . . 10
  - 5.2.3 Glucosa . . . 12
  - 5.2.4 Consumo de tabaco . . . 13
  - 5.2.5 Consumo de alcohol . . . 14
  - 5.2.6 Actividad física . . . 15
  - 5.2.7 Presencia de enfermedad cardiovascular . . . 16

6 Diagramas de caja de las variables numéricas 18
- 6.1 Edad . . . 18
- 6.2 Altura . . . 19
- 6.3 Peso . . . 20
- 6.4 Presión sistólica . . . 21
- 6.5 Presión diastólica . . . 22

7 Histogramas y tablas de frecuencia **23**
7.1 Edad (age) . . . 23
7.2 Altura (height) . . . 25
7.3 Peso (weight) . . . 27
7.4 Presión sistólica (ap_hi) . . . 29
7.5 Presión diastólica (ap_lo) . . . 31

8 Interpretación de los histogramas **33**
8.1 Interpretación de la edad . . . 34
8.2 Interpretación de la altura . . . 34
8.3 Interpretación del peso . . . 35
8.4 Interpretación de la presión sistólica y diastólica . . . 35

9 Conclusión **35**

1 Introducción

En este trabajo se realiza un Análisis Exploratorio de Datos (EDA) sobre un conjunto de datos relacionado con enfermedades cardiovasculares.

El archivo original fue descargado y procesado previamente mediante el script Bash `descarga.sh`. El resultado de ese proceso es el archivo `dataset.csv`, que se utiliza para realizar el análisis en R con Quarto y el paquete `tidyverse`.

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ------------------------ tidyverse 2.0.0 --
v dplyr     1.2.1     v readr     2.2.0
v forcats   1.0.1     v stringr   1.6.0
v ggplot2   4.0.3     v tibble    3.3.1
v lubridate 1.9.5     v tidyr     1.3.2
v purrr     1.2.2
-- Conflicts ------------------------------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to beco
```

2 Importación y descripción del dataset

Se importa el archivo `dataset.csv`, utilizando `;` como separador de columnas.

```r
dataset <- read_delim(
  "../datos/procesados/dataset.csv",
  delim = ";",
  show_col_types = FALSE
)
```

Primero se observa la dimensión del dataset y los nombres de sus variables.

```r
dim(dataset)
```

```
[1] 68666    13
```

```r
names(dataset)
```

```
 [1] "id"          "age"         "gender"      "height"      "weight"
 [6] "ap_hi"       "ap_lo"       "cholesterol" "gluc"        "smoke"
[11] "alco"        "active"      "cardio"
```

La función `glimpse()` permite observar rápidamente el tipo de dato de cada variable y algunos de sus valores.

```r
glimpse(dataset)
```

```
Rows: 68,666
Columns: 13
$ id          <dbl> 0, 1, 2, 3, 4, 8, 9, 12, 13, 14, 15, 16, 18, 21, 23, 24, 2~
$ age         <dbl> 50.3918, 55.4192, 51.6630, 48.2822, 47.8740, 60.0384, 60.5~
$ gender      <dbl> 2, 1, 1, 2, 1, 1, 1, 2, 1, 1, 1, 2, 2, 1, 2, 2, 1, 1, 1, 2~
$ height      <dbl> 168, 156, 165, 169, 156, 151, 157, 178, 158, 164, 169, 173~
$ weight      <dbl> 62, 85, 64, 82, 56, 67, 93, 95, 71, 68, 80, 60, 60, 78, 95~
$ ap_hi       <dbl> 110, 140, 130, 150, 100, 120, 130, 130, 110, 110, 120, 120~
$ ap_lo       <dbl> 80, 90, 70, 100, 60, 80, 80, 90, 70, 60, 80, 80, 80, 70, 9~
$ cholesterol <dbl> 1, 3, 3, 1, 1, 2, 3, 3, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~
$ gluc        <dbl> 1, 1, 1, 1, 1, 2, 1, 3, 1, 1, 1, 1, 1, 1, 1, 1, 1, 3, 1, 1~
$ smoke       <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 1~
$ alco        <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0~
$ active      <dbl> 1, 1, 0, 1, 0, 0, 1, 1, 1, 0, 1, 1, 0, 1, 1, 0, 0, 1, 0, 1~
$ cardio      <dbl> 0, 1, 1, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0~
```

También se utiliza `summary()` para obtener una primera descripción estadística de las variables.

```
summary(dataset)
```

```
       id              age            gender          height
 Min.   :    0   Min.   :29.58   Min.   :1.000   Min.   : 55.0
 1st Qu.:25006   1st Qu.:48.38   1st Qu.:1.000   1st Qu.:159.0
 Median :50013   Median :53.98   Median :1.000   Median :165.0
 Mean   :49977   Mean   :53.33   Mean   :1.349   Mean   :164.4
 3rd Qu.:74870   3rd Qu.:58.42   3rd Qu.:2.000   3rd Qu.:170.0
 Max.   :99999   Max.   :64.97   Max.   :2.000   Max.   :250.0
     weight           ap_hi           ap_lo        cholesterol
 Min.   : 11.00   Min.   : 70.0   Min.   : 40.0   Min.   :1.000
 1st Qu.: 65.00   1st Qu.:120.0   1st Qu.: 80.0   1st Qu.:1.000
 Median : 72.00   Median :120.0   Median : 80.0   Median :1.000
 Mean   : 74.12   Mean   :126.7   Mean   : 81.3   Mean   :1.365
 3rd Qu.: 82.00   3rd Qu.:140.0   3rd Qu.: 90.0   3rd Qu.:2.000
 Max.   :200.00   Max.   :240.0   Max.   :150.0   Max.   :3.000
      gluc            smoke              alco             active
 Min.   :1.000   Min.   :0.00000   Min.   :0.00000   Min.   :0.0000
 1st Qu.:1.000   1st Qu.:0.00000   1st Qu.:0.00000   1st Qu.:1.0000
 Median :1.000   Median :0.00000   Median :0.00000   Median :1.0000
 Mean   :1.226   Mean   :0.08798   Mean   :0.05336   Mean   :0.8034
 3rd Qu.:1.000   3rd Qu.:0.00000   3rd Qu.:0.00000   3rd Qu.:1.0000
 Max.   :3.000   Max.   :1.00000   Max.   :1.00000   Max.   :1.0000
     cardio
 Min.   :0.0000
 1st Qu.:0.0000
 Median :0.0000
 Mean   :0.4947
 3rd Qu.:1.0000
 Max.   :1.0000
```

El dataset contiene **68.666 observaciones y 13 variables**. La variable `age` fue transformada previamente de días a años durante el proceso de limpieza realizado con Bash.

3 Identificación y clasificación de las variables

Las variables se clasifican según el tipo de información que representan.

Variable	Descripción	Clasificación
`id`	Identificador de la observación	Identificadora
`age`	Edad en años	Numérica continua
`gender`	Género codificado	Categórica nominal
`height`	Altura en centímetros	Numérica continua
`weight`	Peso en kilogramos	Numérica continua
`ap_hi`	Presión arterial sistólica	Numérica
`ap_lo`	Presión arterial diastólica	Numérica
`cholesterol`	Nivel de colesterol	Categórica ordinal
`gluc`	Nivel de glucosa	Categórica ordinal
`smoke`	Consumo de tabaco	Categórica binaria
`alco`	Consumo de alcohol	Categórica binaria
`active`	Actividad física	Categórica binaria
`cardio`	Presencia de enfermedad cardiovascular	Categórica binaria

La variable `id` se utiliza únicamente para identificar cada observación. Por este motivo no se incluye en las medidas estadísticas ni en los gráficos, ya que su valor numérico no representa una característica del paciente.

4 Medidas de posición de las variables numéricas

Para las variables numéricas se calculan las medidas de tendencia central y las medidas de posición no central.

4.1 Función para calcular la moda

R no tiene una función básica específica para calcular la moda. Por eso se crea una función sencilla que devuelve el valor que más se repite.

```
moda <- function(x) {
  valores <- unique(x)
  valores[which.max(tabulate(match(x, valores)))]
}
```

4.2 Variables numéricas

Se seleccionan las cinco variables numéricas que se analizarán:

```r
variables_numericas <- dataset %>%
  select(age, height, weight, ap_hi, ap_lo)
```

Para facilitar los cálculos, se pasan las variables a formato largo. De esta manera, cada variable queda identificada por su nombre y sus valores quedan en una sola columna.

```r
variables_numericas_largo <- variables_numericas %>%
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "valor"
  )
```

4.3 Medidas de tendencia central y cuartiles

Se calcula una tabla resumen con:

- **Media:** promedio de los valores.
- **Mediana:** valor central de los datos ordenados.
- **Moda:** valor que más se repite.
- **Q1, Q2 y Q3:** cuartiles que dividen los datos en cuatro partes.

```r
resumen_estadistico <- variables_numericas_largo %>%
  group_by(variable) %>%
  summarise(
    media = mean(valor),
    mediana = median(valor),
    moda = moda(valor),
    Q1 = quantile(valor, 0.25),
    Q2 = quantile(valor, 0.50),
    Q3 = quantile(valor, 0.75),
    .groups = "drop"
  )

resumen_estadistico
```

```
# A tibble: 5 x 7
  variable media mediana  moda    Q1    Q2    Q3
  <chr>    <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl>
1 age       53.3    54.0  54.1  48.4  54.0  58.4
```

```
2 ap_hi    127.    120   120   120   120   140
3 ap_lo     81.3    80    80    80    80    90
4 height   164.    165   165   159   165   170
5 weight    74.1    72    65    65    72    82
```

4.4 Deciles

Los deciles dividen los datos ordenados en diez partes. Se calculan desde el primer decil (10 %) hasta el noveno decil (90 %).

```
deciles <- variables_numericas_largo %>%
  group_by(variable) %>%
  reframe(
    decil = 1:9,
    valor = quantile(valor, probs = seq(0.1, 0.9, by = 0.1))
  )

deciles
```

```
# A tibble: 45 x 3
   variable decil valor
   <chr>    <int> <dbl>
 1 age          1  43.4
 2 age          2  46.8
 3 age          3  49.9
 4 age          4  52.0
 5 age          5  54.0
 6 age          6  55.9
 7 age          7  57.9
 8 age          8  59.9
 9 age          9  62.0
10 ap_hi        1 110
# i 35 more rows
```

4.5 Percentiles

Los percentiles permiten conocer la posición de un valor dentro de la distribución. Para resumir los resultados se calculan algunos percentiles representativos.

```r
percentiles <- variables_numericas_largo %>%
  group_by(variable) %>%
  summarise(
    P10 = quantile(valor, 0.10),
    P25 = quantile(valor, 0.25),
    P50 = quantile(valor, 0.50),
    P75 = quantile(valor, 0.75),
    P90 = quantile(valor, 0.90),
    P95 = quantile(valor, 0.95),
    P99 = quantile(valor, 0.99),
    .groups = "drop"
  )

percentiles
```

```
# A tibble: 5 x 8
  variable   P10   P25   P50   P75   P90   P95   P99
  <chr>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 age       43.4  48.4  54.0  58.4  62.0  63.7  64.4
2 ap_hi    110   120   120   140   150   160   180
3 ap_lo     70    80    80    90    90   100   100
4 height   155   159   165   170   175   178   184
5 weight    58    65    72    82    93   100   117
```

5 Análisis de variables categóricas

Las variables `gender`, `cholesterol`, `gluc`, `smoke`, `alco`, `active` y `cardio` son categóricas. Para estas variables no se calculan media, mediana, cuartiles o percentiles, ya que esas medidas están pensadas para variables numéricas.

En cambio, se analiza principalmente:

- la **moda**, es decir, la categoría más frecuente;
- las **frecuencias**;
- los **gráficos de barras**.

```r
variables_categoricas <- c(
  "gender",
  "cholesterol",
  "gluc",
  "smoke",
```

```
  "alco",
  "active",
  "cardio"
)
```

5.1 Moda de las variables categóricas

```
resumen_categoricas <- dataset %>%
  summarise(
    across(
      all_of(variables_categoricas),
      moda
    )
  )

resumen_categoricas
```

```
# A tibble: 1 x 7
  gender cholesterol  gluc smoke  alco active cardio
   <dbl>       <dbl> <dbl> <dbl> <dbl>  <dbl>  <dbl>
1      1           1     1     0     0      1      0
```

5.2 Tablas de frecuencia y gráficos de barras

Para cada variable categórica se calcula la frecuencia absoluta, relativa, porcentual y acumulada.

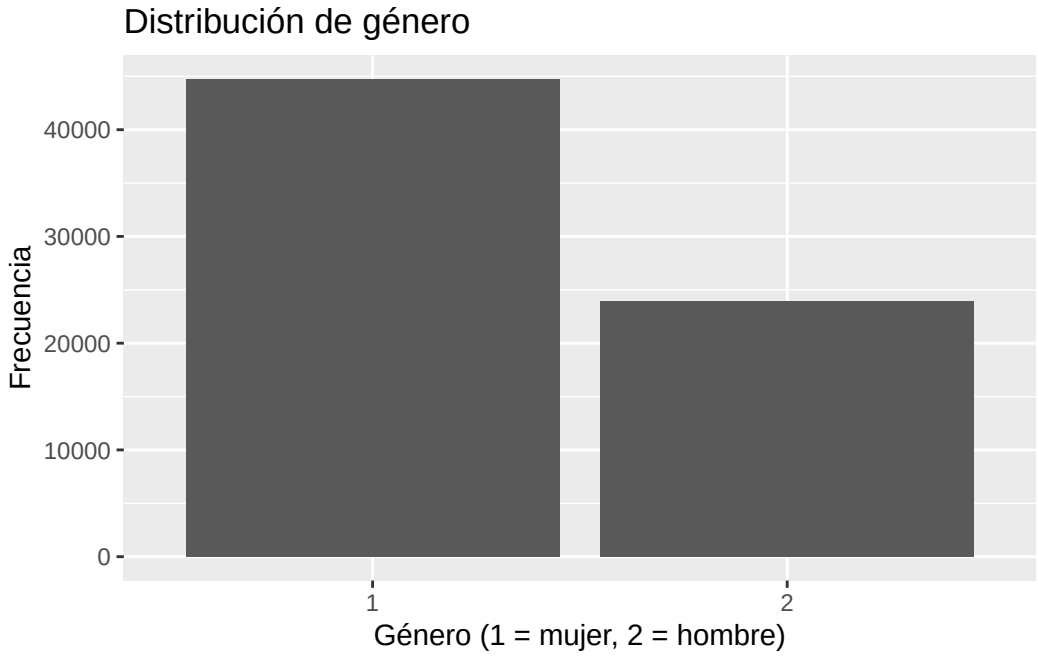
5.2.1 Género

```
tabla_gender <- dataset %>%
  count(gender) %>%
  mutate(
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )

tabla_gender
```

```
# A tibble: 2 x 5
  gender     n frecuencia_relativa frecuencia_porcentual frecuencia_acumulada
   <dbl> <int>               <dbl>                 <dbl>                 <int>
1      1 44727               0.651                  65.1                 44727
2      2 23939               0.349                  34.9                 68666
```

```r
ggplot(dataset, aes(x = factor(gender))) +
  geom_bar() +
  labs(
    title = "Distribución de género",
    x = "Género (1 = mujer, 2 = hombre)",
    y = "Frecuencia"
  )
```



5.2.2 Colesterol

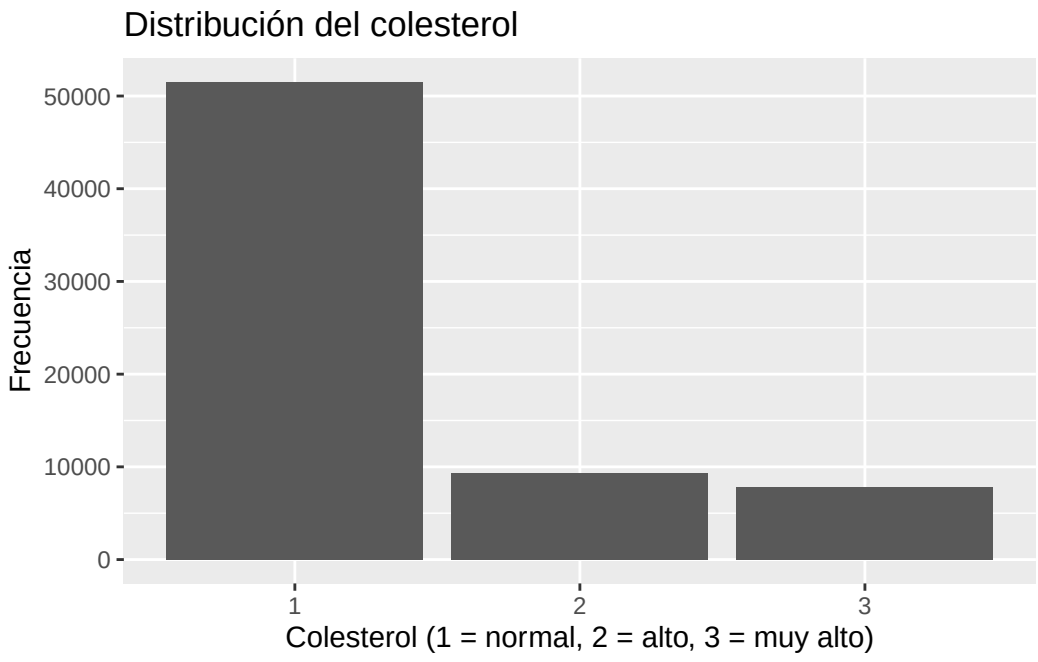
```r
tabla_cholesterol <- dataset %>%
  count(cholesterol) %>%
  mutate(
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
```

```
    frecuencia_acumulada = cumsum(n)
  )

tabla_cholesterol
```

```
# A tibble: 3 x 5
  cholesterol     n frecuencia_relativa frecuencia_porcentual
        <dbl> <int>               <dbl>                 <dbl>
1           1 51497               0.750                  75.0
2           2  9300               0.135                  13.5
3           3  7869               0.115                  11.5
# i 1 more variable: frecuencia_acumulada <int>
```

```
ggplot(dataset, aes(x = factor(cholesterol))) +
  geom_bar() +
  labs(
    title = "Distribución del colesterol",
    x = "Colesterol (1 = normal, 2 = alto, 3 = muy alto)",
    y = "Frecuencia"
  )
```



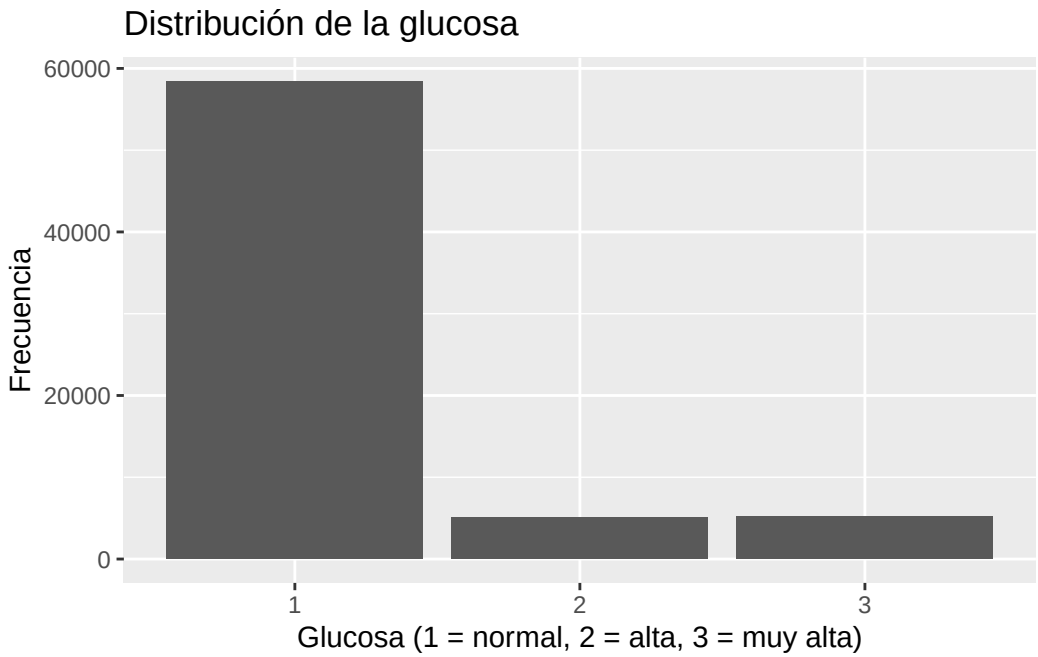
5.2.3 Glucosa

```
tabla_gluc <- dataset %>%
  count(gluc) %>%
  mutate(
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )

tabla_gluc
```

```
# A tibble: 3 x 5
   gluc     n frecuencia_relativa frecuencia_porcentual frecuencia_acumulada
  <dbl> <int>               <dbl>                 <dbl>                 <int>
1     1 58386             0.850                  85.0                  58386
2     2  5065             0.0738                  7.38                 63451
3     3  5215             0.0759                  7.59                 68666
```

```
ggplot(dataset, aes(x = factor(gluc))) +
  geom_bar() +
  labs(
    title = "Distribución de la glucosa",
    x = "Glucosa (1 = normal, 2 = alta, 3 = muy alta)",
    y = "Frecuencia"
  )
```



5.2.4 Consumo de tabaco

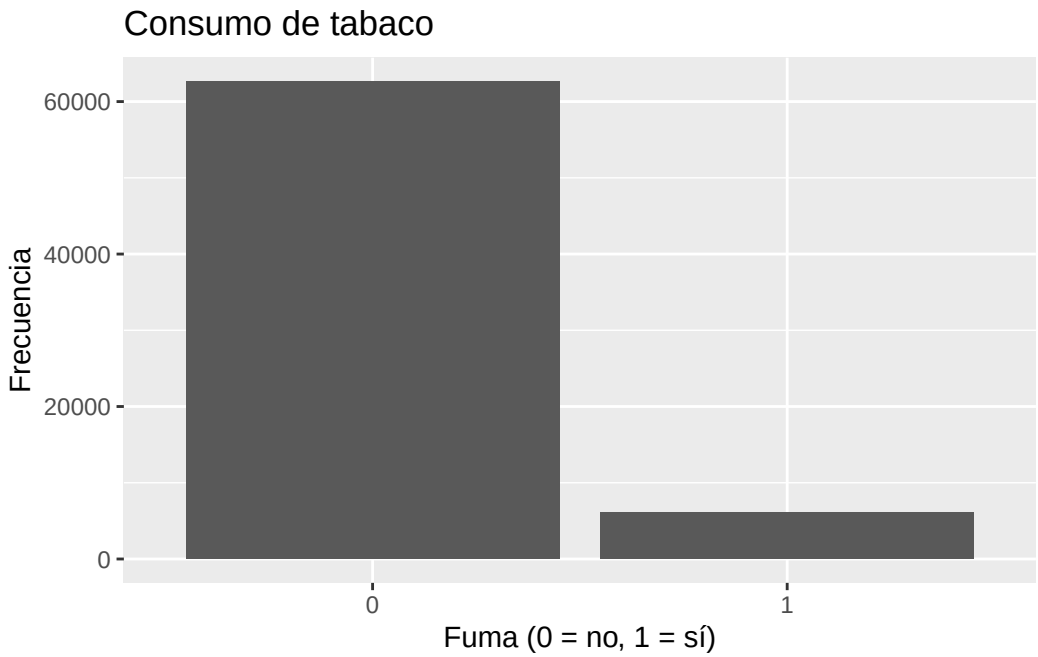
```
tabla_smoke <- dataset %>%
  count(smoke) %>%
  mutate(
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )

tabla_smoke
```

```
# A tibble: 2 x 5
  smoke     n frecuencia_relativa frecuencia_porcentual frecuencia_acumulada
  <dbl> <int>               <dbl>                 <dbl>                 <int>
1     0 62625              0.912                  91.2                  62625
2     1  6041              0.0880                  8.80                 68666
```

```
ggplot(dataset, aes(x = factor(smoke))) +
  geom_bar() +
```

```
  labs(
    title = "Consumo de tabaco",
    x = "Fuma (0 = no, 1 = sí)",
    y = "Frecuencia"
  )
```



5.2.5 Consumo de alcohol

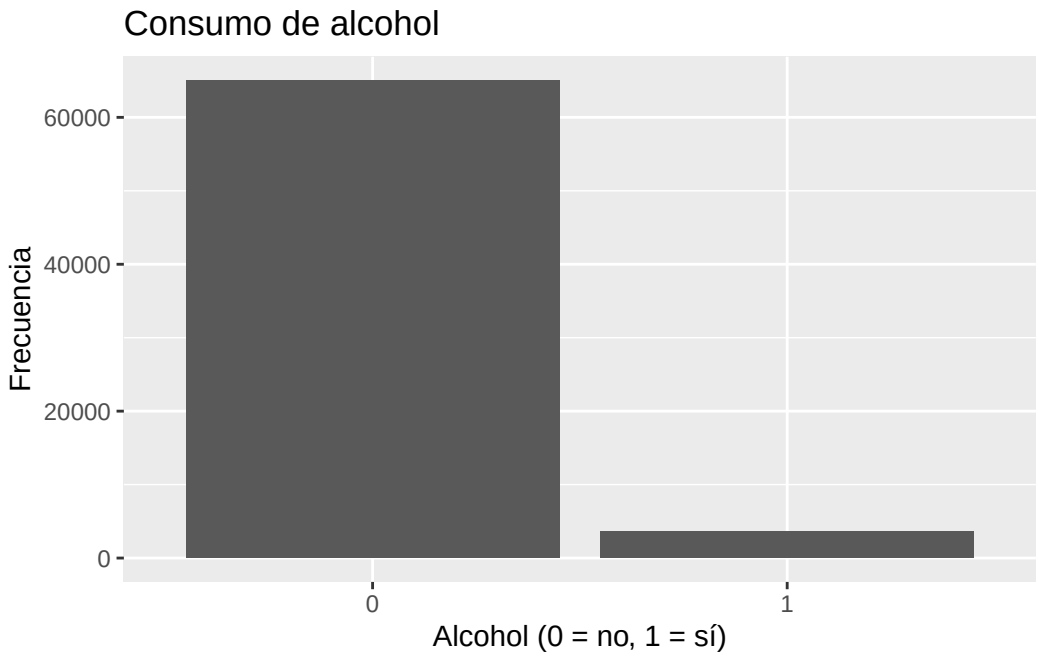
```
tabla_alco <- dataset %>%
  count(alco) %>%
  mutate(
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )

tabla_alco
```

```
# A tibble: 2 x 5
   alco     n frecuencia_relativa frecuencia_porcentual frecuencia_acumulada
```

```
  <dbl> <int>              <dbl>               <dbl>              <int>
1     0 65002              0.947               94.7               65002
2     1  3664              0.0534               5.34              68666
```

```r
ggplot(dataset, aes(x = factor(alco))) +
  geom_bar() +
  labs(
    title = "Consumo de alcohol",
    x = "Alcohol (0 = no, 1 = sí)",
    y = "Frecuencia"
  )
```



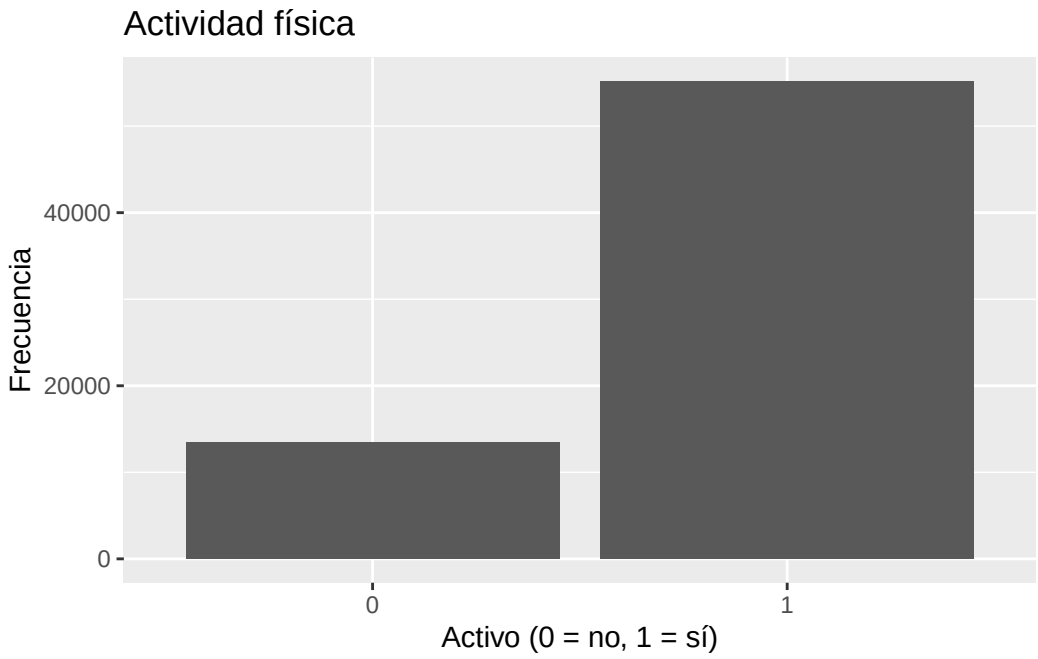
5.2.6 Actividad física

```r
tabla_active <- dataset %>%
  count(active) %>%
  mutate(
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )
```

```r
tabla_active
```

```
# A tibble: 2 x 5
  active     n frecuencia_relativa frecuencia_porcentual frecuencia_acumulada
   <dbl> <int>               <dbl>                 <dbl>                 <int>
1      0 13502               0.197                  19.7                 13502
2      1 55164               0.803                  80.3                 68666
```

```r
ggplot(dataset, aes(x = factor(active))) +
  geom_bar() +
  labs(
    title = "Actividad física",
    x = "Activo (0 = no, 1 = sí)",
    y = "Frecuencia"
  )
```



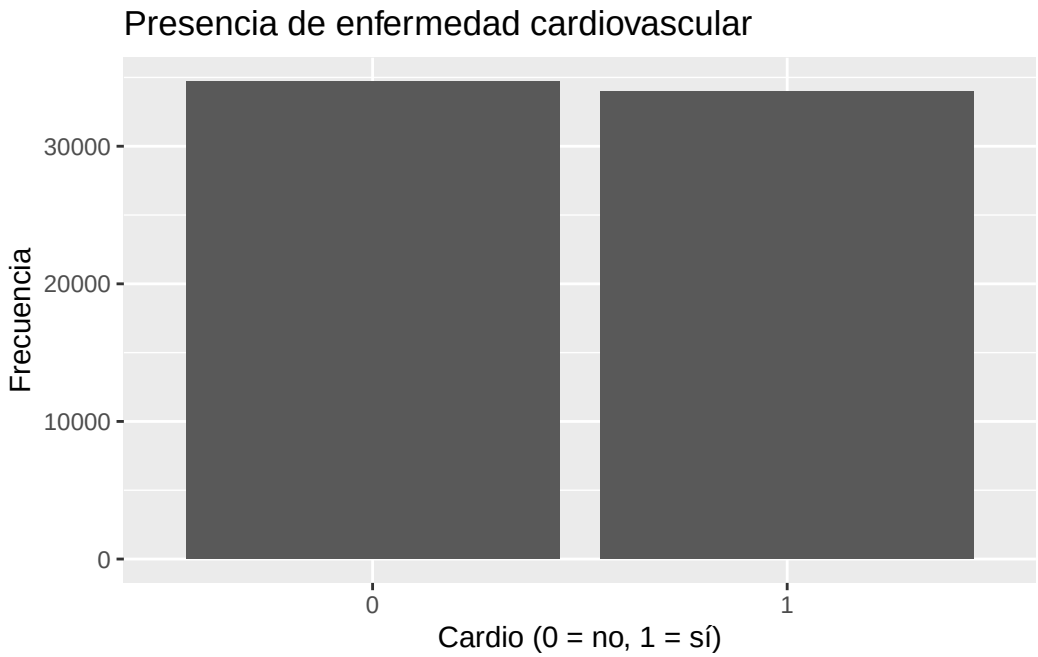
5.2.7 Presencia de enfermedad cardiovascular

```r
tabla_cardio <- dataset %>%
  count(cardio) %>%
  mutate(
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )

tabla_cardio
```

```
# A tibble: 2 x 5
  cardio     n frecuencia_relativa frecuencia_porcentual frecuencia_acumulada
   <dbl> <int>               <dbl>                 <dbl>                 <int>
1      0 34697               0.505                  50.5                 34697
2      1 33969               0.495                  49.5                 68666
```

```r
ggplot(dataset, aes(x = factor(cardio))) +
  geom_bar() +
  labs(
    title = "Presencia de enfermedad cardiovascular",
    x = "Cardio (0 = no, 1 = sí)",
    y = "Frecuencia"
  )
```



Interpretación general: predominan las mujeres (`gender = 1`), los niveles normales de colesterol y glucosa, las personas no fumadoras y no consumidoras de alcohol, y las personas físicamente activas. La variable `cardio` presenta una distribución cercana al equilibrio entre pacientes con y sin enfermedad cardiovascular.

6 Diagramas de caja de las variables numéricas

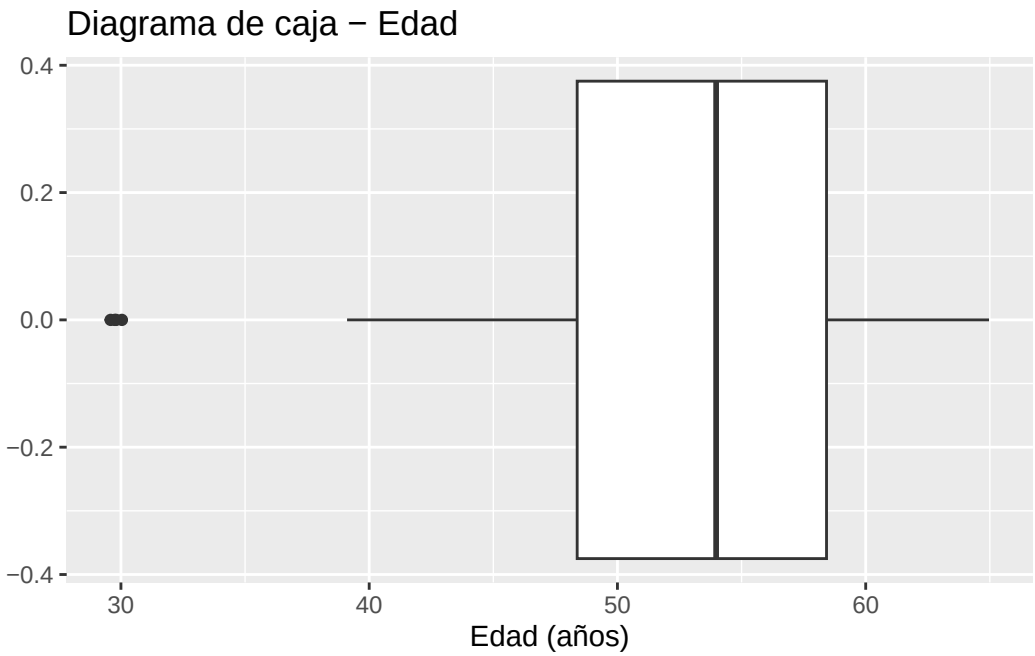
El diagrama de caja permite observar de forma gráfica:

- la mediana;
- los cuartiles;
- el rango intercuartílico;
- posibles valores atípicos.

6.1 Edad

```
ggplot(dataset, aes(x = age)) +
  geom_boxplot() +
  labs(
    title = "Diagrama de caja - Edad",
```

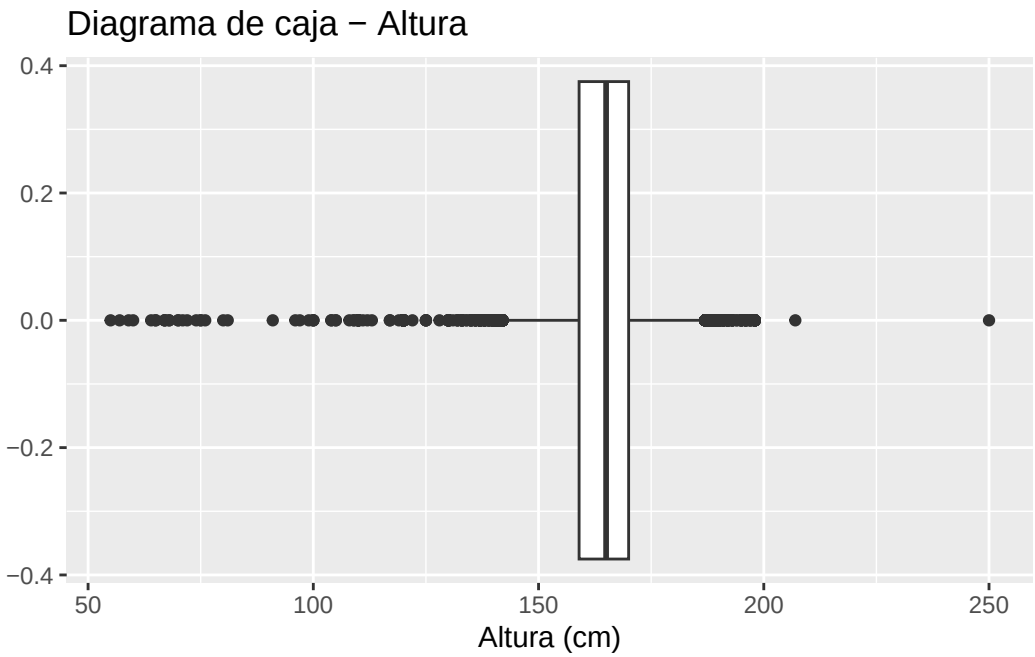
```
    x = "Edad (años)"
  )
```



Interpretación: la mayor parte de las edades se concentra en un rango relativamente definido. También se observan algunos valores atípicos correspondientes a pacientes con edades considerablemente menores que el resto de la muestra.

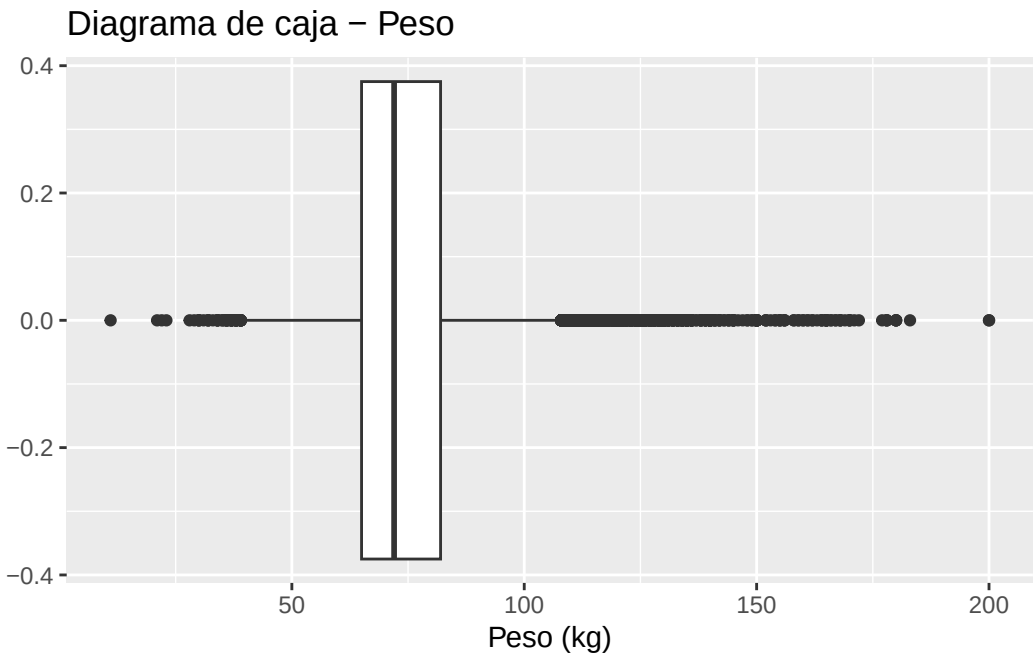
6.2 Altura

```
ggplot(dataset, aes(x = height)) +
  geom_boxplot() +
  labs(
    title = "Diagrama de caja - Altura",
    x = "Altura (cm)"
  )
```



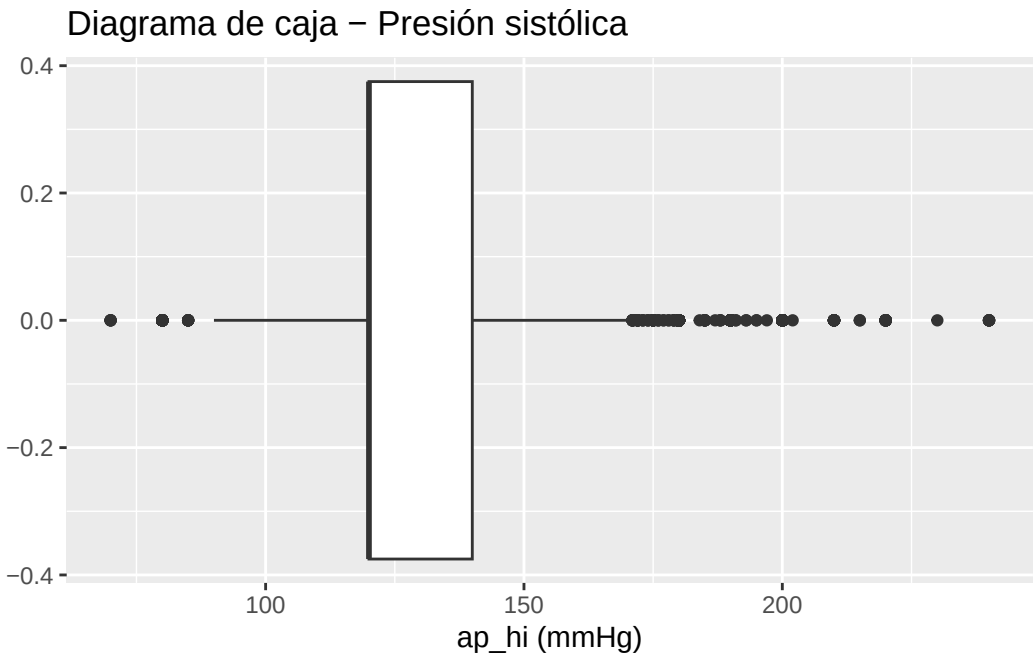
6.3 Peso

```
ggplot(dataset, aes(x = weight)) +
  geom_boxplot() +
  labs(
    title = "Diagrama de caja - Peso",
    x = "Peso (kg)"
  )
```



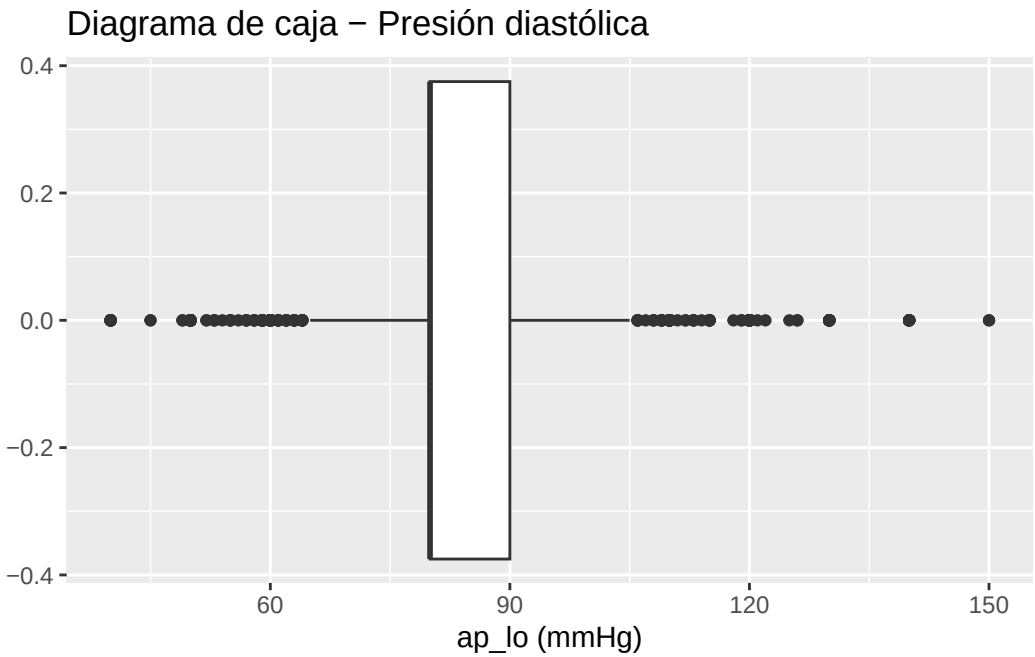
6.4 Presión sistólica

```
ggplot(dataset, aes(x = ap_hi)) +
  geom_boxplot() +
  labs(
    title = "Diagrama de caja - Presión sistólica",
    x = "ap_hi (mmHg)"
  )
```



6.5 Presión diastólica

```
ggplot(dataset, aes(x = ap_lo)) +
  geom_boxplot() +
  labs(
    title = "Diagrama de caja - Presión diastólica",
    x = "ap_lo (mmHg)"
  )
```



7 Histogramas y tablas de frecuencia

Para cada variable numérica se construye una tabla de frecuencias y un histograma.

El procedimiento es el siguiente:

1. Se definen los **intervalos de clase** mediante sus límites inferior y superior.
2. La **amplitud** es el tamaño de cada intervalo.
3. La **marca de clase** es el punto medio del intervalo.
4. Se calcula la frecuencia absoluta, relativa, porcentual y acumulada.
5. Se construye el histograma utilizando los mismos límites de los intervalos.

De esta manera, la tabla de frecuencias y el histograma representan la misma agrupación de los datos.

7.1 Edad (age)

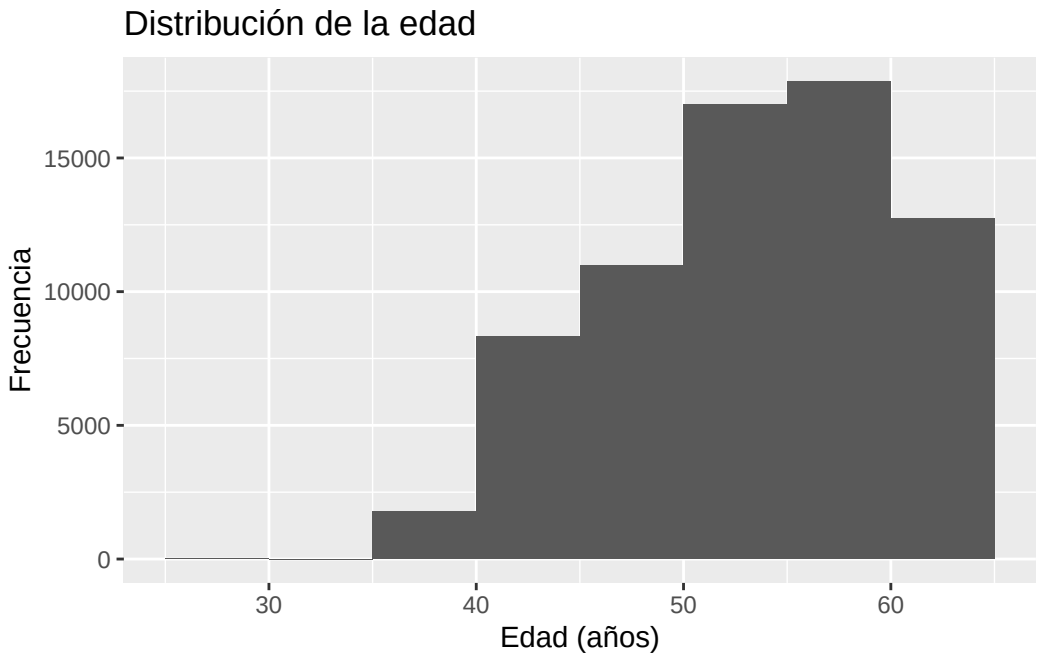
La edad se agrupa en intervalos de 5 años. Por lo tanto, la amplitud de cada intervalo es de **5 años**.

```r
tabla_edad <- dataset %>%
  mutate(
    intervalo = cut(
      age,
      breaks = seq(25, 65, by = 5),
      right = TRUE,
      include.lowest = TRUE
    )
  ) %>%
  count(intervalo, .drop = FALSE) %>%
  mutate(
    marca_clase = 25 + (row_number() - 0.5) * 5,
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )

tabla_edad
```

```
# A tibble: 8 x 6
  intervalo     n marca_clase frecuencia_relativa frecuencia_porcentual
  <fct>     <int>       <dbl>               <dbl>                 <dbl>
1 [25,30]       3        27.5           0.0000437               0.00437
2 (30,35]       1        32.5           0.0000146               0.00146
3 (35,40]    1768        37.5           0.0257                  2.57
4 (40,45]    8329        42.5           0.121                  12.1
5 (45,50]   10968        47.5           0.160                  16.0
6 (50,55]   16989        52.5           0.247                  24.7
7 (55,60]   17856        57.5           0.260                  26.0
8 (60,65]   12752        62.5           0.186                  18.6
# i 1 more variable: frecuencia_acumulada <int>
```

```r
ggplot(dataset, aes(x = age)) +
  geom_histogram(
    breaks = seq(25, 65, by = 5)
  ) +
  labs(
    title = "Distribución de la edad",
    x = "Edad (años)",
    y = "Frecuencia"
  )
```



7.2 Altura (`height`)

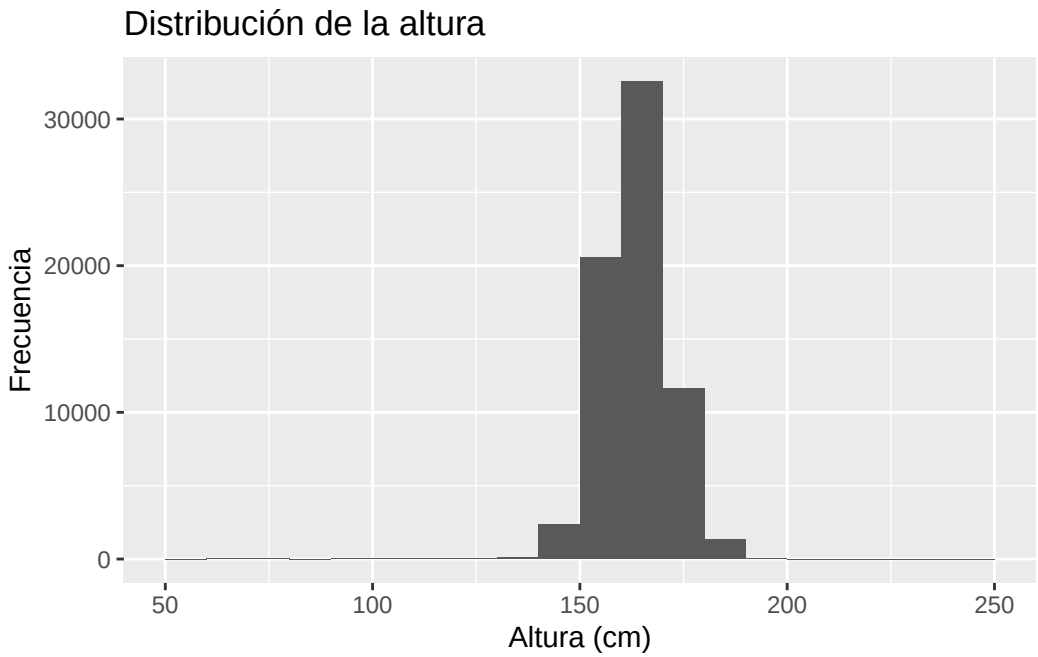
La altura se agrupa en intervalos de 10 cm. La amplitud de cada intervalo es de **10 cm**.

```
tabla_height <- dataset %>%
  mutate(
    intervalo = cut(
      height,
      breaks = seq(50, 250, by = 10),
      right = TRUE,
      include.lowest = TRUE
    )
  ) %>%
  count(intervalo, .drop = FALSE) %>%
  mutate(
    marca_clase = 50 + (row_number() - 0.5) * 10,
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )

tabla_height
```

```
# A tibble: 20 x 6
   intervalo     n marca_clase frecuencia_relativa frecuencia_porcentual
   <fct>     <int>       <dbl>               <dbl>                 <dbl>
 1 [50,60]       4          55           0.0000583               0.00583
 2 (60,70]      10          65           0.000146                0.0146
 3 (70,80]       7          75           0.000102                0.0102
 4 (80,90]       1          85           0.0000146               0.00146
 5 (90,100]      7          95           0.000102                0.0102
 6 (100,110]    14         105           0.000204                0.0204
 7 (110,120]    39         115           0.000568                0.0568
 8 (120,130]    18         125           0.000262                0.0262
 9 (130,140]    96         135           0.00140                 0.140
10 (140,150]  2334         145           0.0340                  3.40
11 (150,160] 20545         155           0.299                  29.9
12 (160,170] 32549         165           0.474                  47.4
13 (170,180] 11642         175           0.170                  17.0
14 (180,190]  1337         185           0.0195                  1.95
15 (190,200]    61         195           0.000888                0.0888
16 (200,210]     1         205           0.0000146               0.00146
17 (210,220]     0         215           0                       0
18 (220,230]     0         225           0                       0
19 (230,240]     0         235           0                       0
20 (240,250]     1         245           0.0000146               0.00146
# i 1 more variable: frecuencia_acumulada <int>
```

```r
ggplot(dataset, aes(x = height)) +
  geom_histogram(
    breaks = seq(50, 250, by = 10)
  ) +
  labs(
    title = "Distribución de la altura",
    x = "Altura (cm)",
    y = "Frecuencia"
  )
```



7.3 Peso (`weight`)

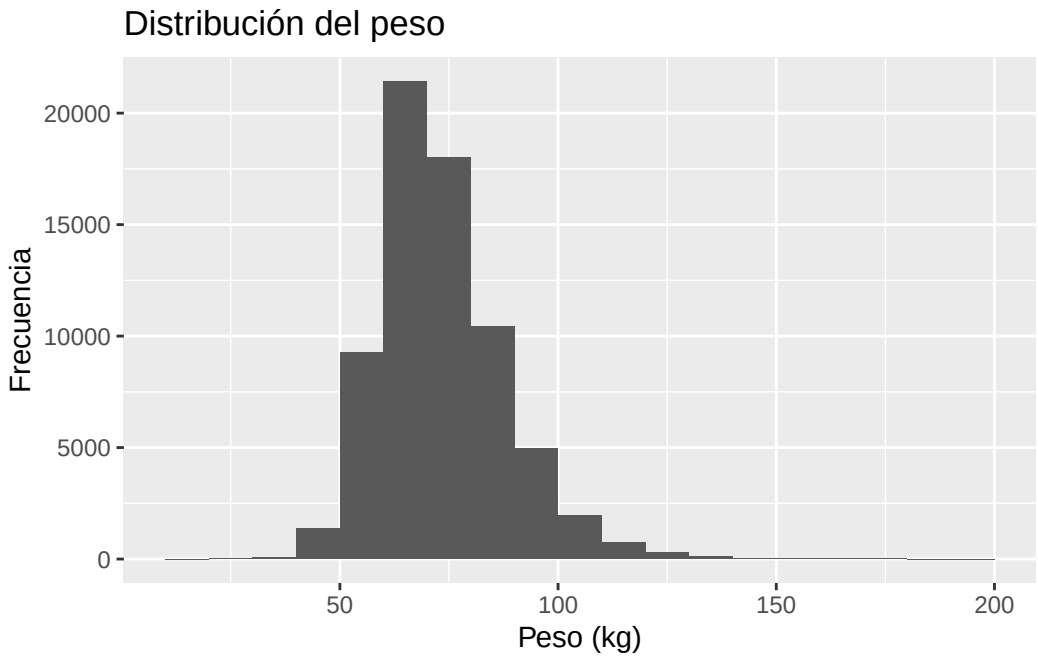
El peso se agrupa en intervalos de 10 kg. La amplitud de cada intervalo es de **10 kg**.

```
tabla_weight <- dataset %>%
  mutate(
    intervalo = cut(
      weight,
      breaks = seq(10, 200, by = 10),
      right = TRUE,
      include.lowest = TRUE
    )
  ) %>%
  count(intervalo, .drop = FALSE) %>%
  mutate(
    marca_clase = 10 + (row_number() - 0.5) * 10,
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )

tabla_weight
```

```
# A tibble: 19 x 6
   intervalo     n marca_clase frecuencia_relativa frecuencia_porcentual
   <fct>     <int>       <dbl>               <dbl>                 <dbl>
 1 [10,20]       1          15           0.0000146               0.00146
 2 (20,30]       8          25           0.000117                0.0117
 3 (30,40]      82          35           0.00119                 0.119
 4 (40,50]    1380          45           0.0201                  2.01
 5 (50,60]    9252          55           0.135                  13.5
 6 (60,70]   21415          65           0.312                  31.2
 7 (70,80]   18010          75           0.262                  26.2
 8 (80,90]   10447          85           0.152                  15.2
 9 (90,100]   4942          95           0.0720                  7.20
10 (100,110]  1937         105           0.0282                  2.82
11 (110,120]   724         115           0.0105                  1.05
12 (120,130]   274         125           0.00399                 0.399
13 (130,140]   101         135           0.00147                 0.147
14 (140,150]    37         145           0.000539                0.0539
15 (150,160]    18         155           0.000262                0.0262
16 (160,170]    25         165           0.000364                0.0364
17 (170,180]    10         175           0.000146                0.0146
18 (180,190]     1         185           0.0000146               0.00146
19 (190,200]     2         195           0.0000291               0.00291
# i 1 more variable: frecuencia_acumulada <int>
```

```r
ggplot(dataset, aes(x = weight)) +
  geom_histogram(
    breaks = seq(10, 200, by = 10)
  ) +
  labs(
    title = "Distribución del peso",
    x = "Peso (kg)",
    y = "Frecuencia"
  )
```



7.4 Presión sistólica (ap_hi)

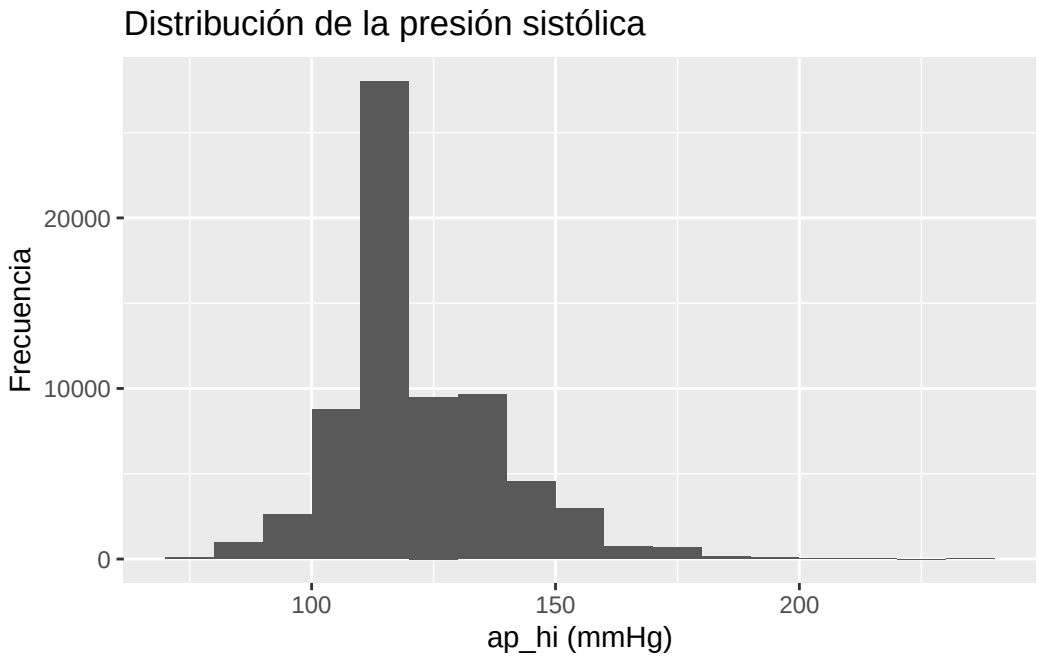
La presión sistólica se agrupa en intervalos de 10 mmHg. La amplitud de cada intervalo es de **10 mmHg**.

```
tabla_ap_hi <- dataset %>%
  mutate(
    intervalo = cut(
      ap_hi,
      breaks = seq(70, 240, by = 10),
      right = TRUE,
      include.lowest = TRUE
    )
  ) %>%
  count(intervalo, .drop = FALSE) %>%
  mutate(
    marca_clase = 70 + (row_number() - 0.5) * 10,
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )
```

```
tabla_ap_hi
```

```
# A tibble: 17 x 6
   intervalo     n marca_clase frecuencia_relativa frecuencia_porcentual
   <fct>     <int>       <dbl>                <dbl>                  <dbl>
 1 [70,80]      65          75            0.000947                 0.0947
 2 (80,90]     963          85            0.0140                   1.40
 3 (90,100]   2612          95            0.0380                   3.80
 4 (100,110]  8759         105            0.128                   12.8
 5 (110,120] 27991         115            0.408                   40.8
 6 (120,130]  9499         125            0.138                   13.8
 7 (130,140]  9634         135            0.140                   14.0
 8 (140,150]  4527         145            0.0659                   6.59
 9 (150,160]  2944         155            0.0429                   4.29
10 (160,170]   740         165            0.0108                   1.08
11 (170,180]   653         175            0.00951                  0.951
12 (180,190]   127         185            0.00185                  0.185
13 (190,200]   101         195            0.00147                  0.147
14 (200,210]    22         205            0.000320                 0.0320
15 (210,220]    21         215            0.000306                 0.0306
16 (220,230]     1         225            0.0000146                0.00146
17 (230,240]     7         235            0.000102                 0.0102
# i 1 more variable: frecuencia_acumulada <int>
```

```
ggplot(dataset, aes(x = ap_hi)) +
  geom_histogram(
    breaks = seq(70, 240, by = 10)
  ) +
  labs(
    title = "Distribución de la presión sistólica",
    x = "ap_hi (mmHg)",
    y = "Frecuencia"
  )
```



7.5 Presión diastólica (`ap_lo`)

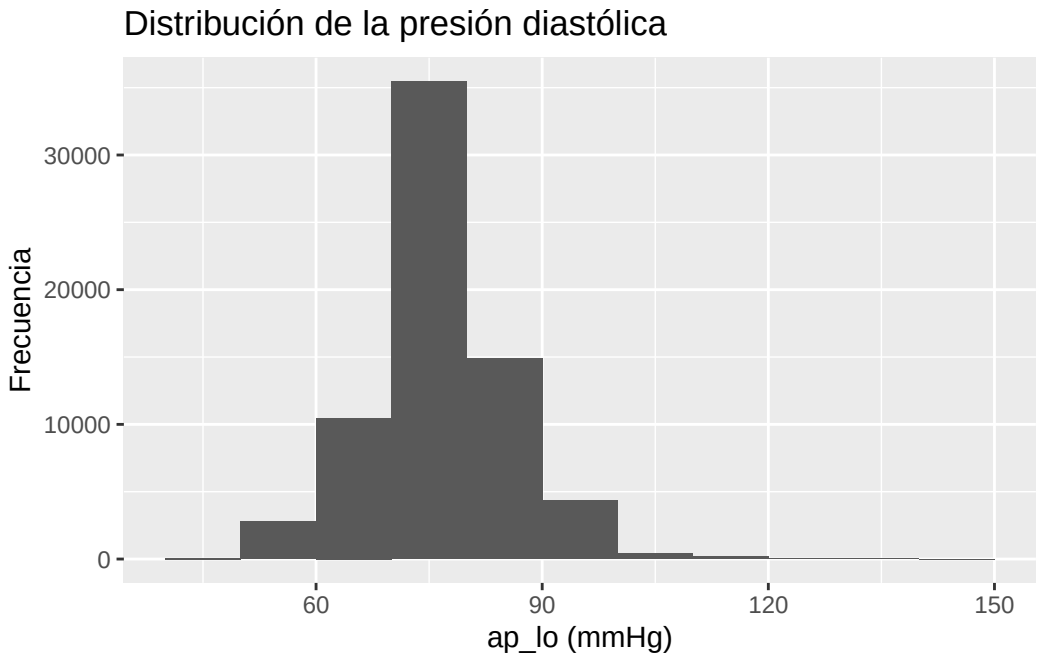
La presión diastólica se agrupa en intervalos de 10 mmHg. La amplitud de cada intervalo es de **10 mmHg**.

```
tabla_ap_lo <- dataset %>%
  mutate(
    intervalo = cut(
      ap_lo,
      breaks = seq(40, 150, by = 10),
      right = TRUE,
      include.lowest = TRUE
    )
  ) %>%
  count(intervalo, .drop = FALSE) %>%
  mutate(
    marca_clase = 40 + (row_number() - 0.5) * 10,
    frecuencia_relativa = n / sum(n),
    frecuencia_porcentual = frecuencia_relativa * 100,
    frecuencia_acumulada = cumsum(n)
  )
```

```r
tabla_ap_lo
```

```
# A tibble: 11 x 6
   intervalo     n marca_clase frecuencia_relativa frecuencia_porcentual
   <fct>     <int>       <dbl>               <dbl>                 <dbl>
 1 [40,50]      75          45           0.00109                 0.109
 2 (50,60]    2755          55           0.0401                  4.01
 3 (60,70]   10470          65           0.152                  15.2
 4 (70,80]   35451          75           0.516                  51.6
 5 (80,90]   14872          85           0.217                  21.7
 6 (90,100]   4365          95           0.0636                  6.36
 7 (100,110]   443         105           0.00645                 0.645
 8 (110,120]   195         115           0.00284                 0.284
 9 (120,130]    24         125           0.000350                0.0350
10 (130,140]    14         135           0.000204                0.0204
11 (140,150]     2         145           0.0000291               0.00291
# i 1 more variable: frecuencia_acumulada <int>
```

```r
ggplot(dataset, aes(x = ap_lo)) +
  geom_histogram(
    breaks = seq(40, 150, by = 10)
  ) +
  labs(
    title = "Distribución de la presión diastólica",
    x = "ap_lo (mmHg)",
    y = "Frecuencia"
  )
```



8 Interpretación de los histogramas

Para complementar la interpretación visual se calcula el coeficiente de asimetría de cada variable.

- Un valor cercano a **0** indica una distribución aproximadamente simétrica.
- Un valor **positivo** indica asimetría hacia la derecha, es decir, una cola hacia valores altos.
- Un valor **negativo** indica asimetría hacia la izquierda, es decir, una cola hacia valores bajos.

```
asimetria <- function(x) {
  n <- length(x)
  m <- mean(x)
  s <- sd(x)

  (sum((x - m)^3) / n) / s^3
}
```

```
tabla_asimetria <- tibble(
  variable = c("age", "height", "weight", "ap_hi", "ap_lo"),
```

```
  asimetria = c(
    asimetria(dataset$age),
    asimetria(dataset$height),
    asimetria(dataset$weight),
    asimetria(dataset$ap_hi),
    asimetria(dataset$ap_lo)
  )
)

tabla_asimetria
```

```
# A tibble: 5 x 2
  variable asimetria
  <chr>        <dbl>
1 age         -0.306
2 height      -0.610
3 weight       1.01
4 ap_hi        0.932
5 ap_lo        0.317
```

8.1 Interpretación de la edad

La mayor concentración de pacientes se encuentra entre los **50 y 60 años**. Las medidas de tendencia central también se encuentran cerca de los 54 años, lo que indica que el centro de la distribución se ubica aproximadamente en esa edad.

Además, se observan algunas edades considerablemente menores que el resto de la muestra, que aparecen como posibles valores atípicos en el diagrama de caja. Esto genera una ligera extensión de la distribución hacia las edades más bajas.

8.2 Interpretación de la altura

La mayor parte de las observaciones se concentra alrededor de valores centrales de altura. El histograma permite observar cómo se agrupan las alturas, mientras que el diagrama de caja permite identificar algunos valores alejados del grupo principal, especialmente alturas muy bajas o muy altas.

8.3 Interpretación del peso

La distribución del peso presenta una mayor concentración en valores bajos y medios, junto con una extensión hacia pesos más elevados. Esta característica se refleja en una asimetría hacia la derecha y en la presencia de algunos valores altos alejados del resto de la muestra.

8.4 Interpretación de la presión sistólica y diastólica

Las variables `ap_hi` y `ap_lo` se concentran principalmente en determinados valores centrales de presión arterial. Sin embargo, también presentan observaciones con valores considerablemente superiores al grupo principal, lo que produce una extensión hacia la derecha y la presencia de valores atípicos en los diagramas de caja.

9 Conclusión

El análisis exploratorio permitió conocer la estructura y distribución de las variables del dataset cardiovascular.

Las variables numéricas fueron analizadas mediante medidas de tendencia central, cuartiles, deciles, percentiles, tablas de frecuencia, histogramas y diagramas de caja. Por otro lado, las variables categóricas fueron analizadas mediante la moda, tablas de frecuencia y gráficos de barras.

En general, la muestra se concentra principalmente en edades adultas, con valores centrales de altura, peso y presión arterial. Los histogramas y diagramas de caja permitieron identificar la forma de las distribuciones y detectar observaciones alejadas del grupo principal.

Este análisis constituye una primera exploración del dataset y permite comprender sus características principales antes de realizar análisis estadísticos o modelos más avanzados.